Лекция 1. Теоретические основы численных методов. *Элементы теории погрешностей*

Один из подходов решения прикладных задач во всех областях науки и техники связан с ***математическим моделированием***, в основе которого заложены знания фундаментальных законов природы и построение на их основе ***математических моделей*** для произвольных технических и научных задач.

Математические модели представляют собой упрощенное описание исследуемого объекта, процесса, явления с помощью ***математических символов и операций над ними***. Основные требования – корректность и адекватность по отношению к реальным процессам с учетом простоты их технической реализации.

Вычислительная математика изучает построение и исследование методов решения математических задач посредством разнообразных вычислений. **Программирование обеспечивает их техническую реализацию**.

Алгоритмы решения множества стандартных задач вычислительной математики реализованы на различных языках программирования.

Коммерческие программные пакеты MATLAB, Mathematica, Maple и другие, а также их свободные альтернативы реализовывают различные численные методы, а также средства для визуализации и отображения результатов. Также большинство **электронных таблиц** могут быть использованы для решения простых задач вычислительной математики.

Следует отметить, что наиболее гибкой, обладающей широким возможностями, позволяющими решить практически любые задачи, является система Mathematica. Система Mathematica разработана фирмой Wolfram Research и постоянно совершенствуется.

Численные методы — раздел вычислительной математики, изучающий приближенные методы решения типовых математических задач, которые либо не решаются, либо трудно решаются точными аналитическими методами.

ВЫЧИСЛИТЕЛЬНАЯ ЗАДАЧА – определить некоторую величину y по известной величине x. Здесь y и x элементы различных множеств (числа, векторы, матрицы, функции и другие)

Символическая запись вычислительной задачи: $y = A(x)$.

Задача $y = A(x)$ называется **корректно поставленной**, если для любых входных данных x (из некоторого множества) решение y существует, единственно и устойчиво по входным данным.

Практически всегда величины, которыми мы будем оперировать, являются элементами ***банаховых*** **пространств** (*линейных нормированных пространств полных относительно метрики, порожденной нормой*).

Если решение *непрерывно* зависит от входных данных, то задача называется *устойчивой* по входным данным.

? Что означает: решение y непрерывно зависит от входных данных x ?

На практике имеем входные данные с погрешностью $x+\delta x$ и находим $y+\delta y = A(x+\delta x)$. Следовательно, погрешность (неустранимая) решения

$$\delta y = A(x+\delta x) - A(x).$$

Решение непрерывно зависит от входных данных, если $\|\delta y\| \to 0$ при $\|\delta x\| \to 0$.

Под *обусловленностью вычислительной задачи* понимают чувствительность ее решения к малым изменениям входных данных. Задачу называют ***хорошо обусловленной***, если при малых изменениях входных данных результат также изменяется незначительно. Задача называется *плохо обусловленной*, если малые изменения входных данных могут привести к большим изменениям решения.

Методы реализации вычислительных задач можно разделить на три группы:
1) графические;
2) аналитические;
3) численные.

Указанные методы используются как самостоятельно, так и совместно.

Замечание о численных и аналитических решениях вычислительных задач.

Аналитические методы позволяют количественно и качественно проанализировать исследуемые параметры модели. *Аналитическое решение, записанное в виде формулы, более информативно. Оно позволяет проследить влияние параметров задачи на характер решения. Найти, однако, аналитическое решение удается лишь в простейших задачах.*

Численные методы решения задачи не выявляют этих закономерностей. Они позволяют свести решение задачи к вычислению конечного числа арифметических действий над числами и получить решение в виде числовых значений. Решение, получаемое численными методами, обычно является приближенным.

Важной задачей является оценка степени точности полученного приближенного решения. Ее принято оценивать некоторой численной величиной, называемой ***погрешностью***.

Основные источники погрешностей

- **Погрешность исходных данных**. Параметры, входящие в описание задачи, заданы неточно. Это могут быть экспериментально измеренные величины.
- **Погрешность математической модели,** которая описывает изучаемый объект приближенно с учетом основных, наиболее существенных факторов.
- **Погрешность метода решения** связана с тем, что точный оператор и исходные данные заменяются приближенными**.**
- **Вычислительная погрешность** возникает из-за округления чисел (погрешность округлений), промежуточных и окончательных результатов счета. Методы, причисляемые к точным, не учитывают наличие вычислительной погрешности.
- **Особенности представления чисел в ЭВМ**

Первые два вида погрешностей называют ***неустранимой погрешностью***. Плохая обусловленность задачи является источником неустранимой погрешности.

Полная погрешность является результатом взаимодействия разных видов погрешностей и не может быть меньше, чем наибольшая из составляющих ее погрешностей.

Прямая задача теории погрешностей – оценить точность результата, зная заданную точность исходных данных.

Обратная задача теории погрешностей – зная требуемую точность результата, найти необходимую точность исходных данных.

При численном решении задач приходится оперировать двумя видами чисел – ***точными*** и ***приближенными.***

К ***точным числам*** *относятся числа, которые* ***дают истинное значение исследуемой величины.***

К ***приближенным*** относятся числа, ***близкие к истинному значению***, причем степень близости и определяется ***погрешностью вычислений***.

Любое десятичное число

$$x = \pm\overline{a_n a_{n-1} \ldots a_1 a_0 a_{-1} a_{-2} \ldots a_{-m} \ldots}$$

представимо в виде

$$x = \pm a_n \cdot 10^n + a_{n-1} \cdot 10^{n-1} + \ \ldots + a_1 \cdot 10 \ + a_0 + \ a_{-1} \cdot 10^{-1} + a_{-2} \cdot 10^{-2} + \ \ldots \ + a_{-m} \cdot 10^{-m} + \ldots,$$

где α_i – цифры числа, 10^i – их позиция ($\pm i$).

Абсолютная и относительная погрешности

Пусть x — точное значение некоторой величины;
a — приближенное значение той же величины ($a \approx x$).

Абсолютная погрешность приближенного числа a определяется как

$$\Delta = |x - a|.$$

В случае когда x неизвестно (в практических задачах оно неизвестно и никогда не будет известно, поскольку определяется с помощью измерений, страдающих неточностями) вводят **предельную абсолютную погрешность** Δ_a — такое значение, которое абсолютная погрешность заведомо не превзойдет при данном способе измерений, т.е.

$$|x - a| \le \Delta_a.$$

Предельная абсолютная погрешность оценивает точность измерений

$$a - \Delta_a \le x \le a + \Delta_a.$$

Предельная абсолютная погрешность определяется неоднозначно.

На практике выбирают наименьшую из возможных при данных условия задачи.

Пример 1. Оценить предельную абсолютную погрешность числа $a = 3{,}14$, заменяющего число π.

Так как имеет место неравенство

$$3{,}14 < \pi < 3{,}15, \text{ то } |\pi - a| < 0{,}01$$

и, следовательно, можно принять $\Delta_a = 0{,}01$.

Если учесть, что

$$3{,}14 < \pi < 3{,}142,$$

то будем иметь лучшую оценку: $\Delta_a = 0{,}002$.

Более информативным показателем качества измерений является **относительная погрешность** δ (соответственно **предельная относительная погрешность** δ_a) приближенного числа a как отношение абсолютной погрешности (предельной абсолютной погрешности) к модулю числа a:

$$\delta = \frac{\Delta}{|a|}, \qquad \delta_a = \frac{\Delta_a}{|a|}.$$

Имеем $\boxed{x = a \pm \Delta_a = a(1 \pm \delta_a).}$

Относительная погрешность является величиной безразмерной и обычно выражается в процентах.

Принято считать, что приближенное число a точнее приближенного числа b, если $\delta_a^* < \delta_b^*$.

Пример 2. Определить, какое «равенство» точнее $\frac{16}{7} = 2{,}29$ или $\sqrt{11} = 3{,}32$?

Пусть a=2,29 приближенное значение дроби $\frac{16}{7} = 2{,}28571428\ldots$ и пусть b=3,32 приближенное значение иррационального числа $\sqrt{11} = 3{,}3166247903\ldots$. Округлим с избытком предельные абсолютные погрешности:

$$\Delta_a = \left|\frac{16}{7} - 2{,}29\right| \le 0{,}00429 \le 0{,}005, \qquad \Delta_b = \left|\sqrt{11} - 3{,}32\right| \le 0{,}00338 \le 0{,}004.$$

Предельные относительные погрешности:

$$\delta_a = \frac{\Delta_a}{|a|} = \frac{0{,}005}{2{,}29} \approx 0{,}0022 = 0{,}2\%, \qquad \delta_b = \frac{\Delta_b}{|b|} = \frac{0{,}004}{3{,}32} \approx 0{,}0012 = 0{,}1\%.$$

Таким образом, приближенное число b точнее приближенного числа a.

Значащие и верные цифры приближенного числа

Значащими цифрами числа называются все его цифры, начиная с первой ненулевой.

Таким образом, в записи приближенного числа значащими цифрами являются:

- все ненулевые цифры;
- нули, содержащиеся между ненулевыми цифрами;
- нули, являющиеся представителями сохраненных десятичных разрядов при округлении.

Значащие цифры подчеркнуты.

2,305; 0,0357; 0,001123; 0,035300.

Определение. Значащую цифру в записи приближенного числа называют ***верной***, если абсолютная погрешность числа не превосходит половины единицы разряда, в котором стоит эта цифра, (***в узком смысле***) или единицы разряда (***в широком смысле***).

Цифры, не являющиеся верными, называются сомнительными.

Пример 3. Пусть x=4,20135±0,00009. Имеем шесть значащих цифр.

Верными являются первые четыре значащие цифры, а цифры 3 и 5 не удовлетворяют определению.

Δ_a=0,00009 > $0{,}5\cdot10^{-5}$ для шестой значащей цифры 5 числа a=4,20135.
Δ_a=0,00009 > $0{,}5\cdot10^{-4}$ для пятой значащей цифры 3 числа 4,20135.
Δ_a=0,00009 < $0{,}5\cdot10^{-3}$ для четвертой значащей цифры 1 числа 4,20135.

В широком смысле верными являются первые пять цифр.
Δ_a=0,00009 > 0,00001 для шестой значащей цифры 5 числа 4,20135.

Δ_a=0,00009 <0,0001 для пятой значащей цифры 3 числа 4,20135.

В тех случаях, когда приближенное число содержит излишнее количество сомнительных значащих цифр, прибегают к округлению.

Округлением числа называется замена его числом с меньшим количеством значащих цифр.

Правило округления чисел (по дополнению)

Чтобы округлить число до n значащих цифр, отбрасывают все его цифры, стоящие справа от n-й значащей цифры, или, если это нужно для сохранения разрядов, заменяют их нулями. При этом:

1) если первая отброшенная цифра меньше 5, то оставшиеся десятичные знаки сохраняют без изменения;

2) если первая из отброшенных цифр больше 5, то к последней оставшейся цифре прибавляют единицу;

3) если первая из отброшенных цифр равна 5 и среди остальных отброшенных цифр есть ненулевые, то к последней оставшейся цифре прибавляют единицу;

3а) если же первая из отброшенных цифр равна 5 и все остальные отброшенные цифры являются нулями, то последняя оставшаяся цифра сохраняется неизменной, если она четная, и увеличивается на единицу, если она нечетная (*правило четной цифры*).

При вычислениях в ЭВМ в стандарте IEEE 754 применяется правило округления до четного. Так, 12,5 будет округлено до 12, а 13,5 – до 14.

!!!! **Точность приближенного числа** зависит от количества **верных** значащих цифр.

Это правило округления гарантирует, что сохраненные значащие цифры числа являются верными в узком смысле, т.е. погрешность округления не превосходит половины разряда, соответствующего последней оставленной значащей цифре.

Правило четной цифры обеспечивает компенсацию знаков ошибок. При многочисленных округлениях избыточные числа будут встречаться примерно с той же частотой, что и недостаточные, и произойдет частичная взаимная компенсация погрешностей округления; результат окажется более точным.

Примеры округления чисел до четырех значащих цифр.

а) $3{,}1415926 \approx 3{,}142$; $\Delta_a = |3{,}142 - 3{,}1415926| < 0{,}00041 < 0{,}0005 = 0{,}5 \cdot 0{,}001$;

б) $1\,256\,410 \approx 1\,256\,000$; $\Delta_a = |1256000 - 1256410| < 500 = 0{,}5 \cdot 1000$;

в) $2{,}997925 \cdot 10^8 \approx 2{,}998 \cdot 10^8$;

$$\Delta_a = |2{,}998 \cdot 10^8 - 2{,}997925 \cdot 10^8| < 0{,}000075 \cdot 10^8 < 0{,}0005 \cdot 10^8 = 0{,}5 \cdot 0{,}001 \cdot 10^8.$$

Соглашения при оперировании понятиями верных значащих цифр.

1) Если число имеет лишь верные цифры, то и его округление имеет также только верные цифры.

2) Совпадение приближенного значения, имеющего все верные значащие цифры, с точным значением *не обязательно*.

3) Абсолютные и относительные погрешности числа принято округлять в большую сторону, так как при округлениях границы неопределенности числа, как правило, увеличиваются.

Пусть точное число x неизвестно, a – его приближенное число, имеющее n верных цифр. Если приближенное число a округлить до n значащих цифр, то полученное новое приближенное число a_1, вообще говоря, будет иметь n верных цифр в широком смысле. В силу неравенства

$$|x - a_1| \le |x - a| + |a - a_1|$$

предельная абсолютная погрешность числа a_1 складывается из абсолютной погрешности числа a и погрешности округления.

4) При изменении формы записи числа количество значащих цифр не должно меняться, т.е. необходимо соблюдать равносильность преобразований, например

$7500 = 0{,}7500 \cdot 10^4$; $0{,}110 \cdot 10^2 = 11{,}0$; – равносильные преобразования;

$7500 = 0{,}75 \cdot 10^4$; $0{,}110 \cdot 10^2 = 11$; – неравносильные преобразования.

Здесь два нуля в первом и один ноль во втором выражениях переведены в разряд незначащих цифр, поэтому следует использовать записи

$$7500 = 0{,}7500 \cdot 10^4 \text{ и } 0{,}110 \cdot 10^2 = 11{,}0.$$

5) При вычислениях желательно сохранять такое количество значащих цифр, чтобы их число не превышало числа верных цифр более чем на одну – две единицы.

Связь относительной погрешности приближенного числа с количеством верных знаков этого числа

Теорема. Если положительное приближенное число a имеет n верных десятичных знаков в узком смысле, то его относительная погрешность δ не превосходит величины $\left(\frac{1}{10}\right)^{n-1}$, деленную на первую значащую цифру α_m данного числа, т.е.

$$\delta \le \frac{1}{\alpha_m}\left(\frac{1}{10}\right)^{n-1}.$$

Следствие. Предельную относительную погрешность приближенного числа

$$a = \alpha_m \cdot 10^m + \alpha_{m-1} \cdot 10^{m-1} + \ldots$$

можно вычислить по формуле

$$\delta_a = \frac{10^{1-n}}{\alpha_m}.$$

Пример. Найти относительную и абсолютную погрешности приближенного числа 3,142.

Здесь $n = 4$, $\alpha_m = 3$, $\delta_a = \frac{10^{1-4}}{3} \approx 0,00033$, $\Delta_a = |a| \cdot \delta_a = 3,142 \cdot 0,00033 \approx 0,001$.

Верные значащие цифры числа характеризуют **ориентировочно** относительную погрешность по схеме: одна верная цифра 10%, две – 1%, три – 0,1% и т.д. Верные значащие цифры после запятой характеризуют абсолютную погрешность или в «узком» или в «широком» смысле.

Погрешности алгебраических операций

Пусть a и b – два приближенных числа.

Теорема. Абсолютная погрешность алгебраической суммы нескольких приближенных чисел не превышает суммы абсолютных погрешностей этих чисел.

В частности, для суммы двух чисел a и b любого знака

$$\Delta_{a \pm b} \le \Delta_a + \Delta_b.$$

Следствие. Абсолютная погрешность алгебраической суммы *не может быть меньше* абсолютной погрешности *наименее точного* из слагаемых, т.е. увеличение точности за счет других слагаемых невозможно. Поэтому бессмысленно сохранять излишние десятичные знаки в более точных слагаемых.

Пример. **Сумма приближенных чисел различной абсолютной точности.**

$a = 414.8$, $b = 0.025$, $c = 24.17$, $d = 0.000\ 326$.

По умолчанию все цифры в этих числах считать в е р н ы м и (в узком или широком смысле).

Найдем абсолютную погрешность числа a:

$$\delta_a = \frac{10^{1-4}}{4} = 0,25 \cdot 10^{-3}, \quad \Delta_a = 414,8 \cdot 0,25 \cdot 10^{-3} = 0,1037.$$

Часто на практике поступают следующим образом: абсолютные погрешности слагаемых равны соответственно 0,1, 0,001, 0,01, 0,000001.

1) Выделим наименее точное число (или числа), т. е. такое, в десятичной записи которого *наименьшее* число верных десятичных знаков. Наименее точное слагаемое — a, поскольку в нем только один верный десятичный знак.
2) Округлим остальные числа так, чтобы каждое из них содержало на один (*запасной*) знак больше, чем выделенное число: $b \to 0.02$, $c \to 24.17$, $d \to 0.00$.
3) Выполним сложение с учетом сохраненных знаков: 414.8 + 0.02 + 24.17 + 0.00 = 438.99.
4) Полученный результат округлим до предпоследнего знака, получим окончательный ответ: 439.0.

Имеем $\Delta_{a+b+c+d} = 0{,}1 + 0{,}001 + 0{,}01 + 0{,}000001 = 0{,}111001,$

$$a + b + c + d = 439{,}0 \pm 0{,}1.$$

Вычислим сумму точно

414.8 + 0.025 + 24.17 + 0.000 326 = 438.995326.

Таким образом, при большом количестве арифметических действий в целях **экономии памяти ЭВМ** обоснована необходимость применения округлений.

Теорема. Если все слагаемые в сумме одного и тот же знака, то предельная относительная погрешность их суммы не превышает наибольшей из предельных относительных погрешностей слагаемых.

Предельная относительная погрешность суммы (разности) двух приближенных чисел равна $\delta_{a \pm b} = \dfrac{\Delta_a + \Delta_b}{|a \pm b|}$.

Относительная погрешность разности может оказаться большой при небольшой абсолютной погрешности. Приведите пример.

Замечание о потере точности при вычитании «близких» чисел. При приближенных вычислениях следует по возможности избегать вычитания двух почти равных приближенных чисел (например, преобразовывая выражения). Если же в силу необходимости приходится вычитать такие числа, то следует уменьшаемое и вычитаемое брать с достаточным числом запасных верных знаков (если такая возможность имеется). Например, если известно, что при вычитании должно пропасть m первых значащих цифр, а в результате требуется сохранить n верных цифр, тогда в уменьшаемом и вычитаемом следует сохранять $m+n$ верных значащих цифр.

Теорема. Относительная погрешность произведения (частного) приближенных чисел, отличных от нуля, не превышает суммы относительных погрешностей этих чисел.

Следствие. Предельная относительная погрешность произведения и частного равна сумме предельных относительных погрешностей этих чисел

$$\delta_{a \cdot b} = \delta_{\frac{a}{b}} = \delta_a + \delta_b.$$

В частности, если $b = k \cdot a$, где k – точное число, то $\Delta_b = |k| \cdot \Delta_a$, $\delta_b = \delta_a$.

Пример. Вычислить произведение и частное приближенных чисел a =13,72 и b = 4,01. Определить число верных значащих цифр в полученном результате, если все цифры чисел a и b верные в узком смысле.

По условию предельные абсолютные погрешности чисел равны: $\Delta_a = \Delta_b = 0,005$, относительные погрешности округляем с избытком

$$\delta_a = \frac{0,005}{13,72} = 0,0003644... < 0,0004, \quad \delta_b = \frac{0,005}{4,01} = 0,0012468... < 0,0013.$$

По теореме предельные относительные погрешности произведения и частного этих чисел равны: $\delta_{a\cdot b} = \delta_{\frac{a}{b}} = \delta_a + \delta_b = 0,0004 + 0,0013 = 0,0017.$

Вычислим произведение $a \cdot b = 13,72 \cdot 4,01 = 55,0172,$ где

$$\Delta_{a\cdot b} = 55,0172 \cdot 0,0017 = 0,0935... < 0,1.$$

Таким образом, результат имеет три верных значащих цифры в широком смысле и может быть записан в виде $13,72 \cdot 4,01 = 55,0\left(1 \pm 0,0017\right)$.

Вычислим частное $\frac{a}{b} = \frac{13,72}{4,01} = 3,421446...,$ где

$$\Delta_{\frac{a}{b}} = 3,421446... \cdot 0,0017 = 0,00581... < 0,006.$$

Таким образом, результат имеет три верных значащих цифры в широком смысле и может быть записан в виде $\frac{13,72}{4,01} = 3,42 \cdot \left(1 \pm 0,0017\right)$. Сколько верных значащих цифр в узком смысле?

Правила оценки предельных погрешностей при локальных ручных расчетах и на этапе подготовки исходных данных для арифметических операций приближенных чисел, в записи которых все ***значащие*** цифры ***верны***:

$$\delta_{a\pm b} = \frac{|a|\delta_a + |b|\delta_b}{|a \pm b|}; \qquad \Delta_{a\pm b} = \Delta_a + \Delta_b;$$

$$\delta_{a\cdot b} = \delta_a + \delta_b; \qquad \Delta_{a\cdot b} = |a \cdot b|\left(\delta_a + \delta_b\right) = |b|\delta_a + |a|\delta_b;$$

$$\delta_{a/b} = \delta_a + \delta_b; \qquad \Delta_{a/b} = \left|\frac{a}{b}\right|\left(\delta_a + \delta_b\right) = \frac{|b|\Delta_a + |a|\Delta_b}{b^2}.$$

Оценка ошибок при вычислении функций

Пусть дана дифференцируемая функция $y = f\left(x\right)$ и a – приближенное значение аргумента x, а Δ_a – его абсолютная погрешность. Тогда за абсолютную погрешность функции можно принять ее приращение или дифференциал:

$$\Delta y \approx dy, \quad \Delta y = \left|f'\left(a\right)\right| \cdot \Delta a.$$

Абсолютные погрешности некоторых элементарных функций $y = f(x)$, a – приближенное значение x, можно получить по формулам:

$y = x^m, \quad \Delta y = \left|ma^{m-1}\right| \cdot \Delta a$

$y = \sqrt{x}, \quad \Delta y = \dfrac{1}{2\sqrt{a}} \cdot \Delta a$

$y = \sin x, \quad \Delta y = \left|\cos a\right| \cdot \Delta a$

$y = \cos x, \quad \Delta y = \left|\sin a\right| \cdot \Delta a$

$y = e^x, \quad \Delta y = e^a \cdot \Delta a$

$y = \ln x, \quad \Delta y = \dfrac{1}{a} \cdot \Delta a$

Для функции n переменных $u = f(x_1, x_2, \ldots x_n)$, где $x_1, x_2, \ldots x_n$ – приближенные величины, а $\Delta_{x_1}, \Delta_{x_2}, \ldots, \Delta_{x_n}$ – их известные предельные абсолютные погрешности. Тогда предельная абсолютная погрешность результата – функции u – для малых Δ_{x_i} вычисляется по формуле

$$\Delta_u = \sum_{i=1}^{n} \left|\frac{\partial f}{\partial x_i}\right| \Delta_{x_i}.$$

За предельную относительную погрешность функции u можно принять величину

$$\delta_u = \sum_{i=1}^{n} \left|\frac{\partial}{\partial x_i} \ln u\right| \Delta_{x_i}.$$

Представление действительных чисел в ЭВМ

Нормализованная форма числа. Приближенные числа принято записывать таким образом, чтобы все цифры числа, кроме нулей впереди, если они есть, были значащими и верными цифрами.

Запись числа x в ***нормализованной форме*** имеет вид

$$x = x^0 \cdot 10^p; \qquad \text{где} \quad 0{,}1 \le |x^0| < 1.$$

Число x^0 называется ***мантиссой*** числа x, а число p – его ***порядком***.

Например, для числа $620 = 0{,}620 \cdot 10^3$ мантиссой является 0,620, а порядком – число 3. Заметим, что в этой записи все цифры после запятой верные.

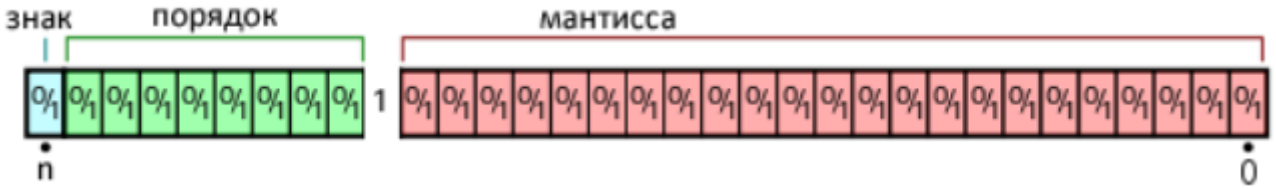
При вычислениях в ЭВМ в стандарте IEEE 754 используется представление действительных чисел в форме с плавающей запятой

$$M \times B^E,$$

где B – основание системы счисления, E – порядок числа, M – мантисса числа.

Главные достоинства чисел с плавающей точкой – возможность производить вычисления в большом диапазоне значений, причем вычисления организуются инструментарием двоичной арифметики, легко реализуемой на вычислительном устройстве.

Два основных формата для чисел с плавающей точкой (ЧПТ) — float (с одинарной точностью) и double (двойной).



Числа с одинарной точностью состоят из 32 битов: одного знакового бита, восьми битов для экспоненты и 23 битов для мантиссы. Формат float позволяет представлять до 7 верных десятичных цифр в двоичной мантиссе, содержащей 24 разряда. Числа с двойной точностью — из 64 битов: одного знакового бита, 11 битов для экспоненты и 52 битов для мантиссы (до 15 верных десятичных цифр в мантиссе).



Рисунок взят из Википедии

В этом примере:

- Знак s=0 (положительное число)
- Порядок $E=01111100_2-127_{10} = -3$
- Мантисса $M = 1.01_2$ (первая единица не явная)
- В результате наше число $F = 1.01_2e-3 = 2^{-3}+2^{-5} = 0,125 + 0,03125 = 0,15625$

Проблема катастрофической неточности вычислений возникает при проведении арифметических операций над десятичными числами при использовании двоичной арифметики. Причина ошибочных вычислений с ЧПТ, главным образом, обусловлена ни ошибками округления, устранению которых в стандарте уделяется большое внимание, а самой природой конвертации десятичных и двоичных чисел.

Непредставимые в двоичном машинном слове десятичные числа, после приведения их к десятичному виду, содержат как верные цифры так и «хвосты» из неверных цифр. Эти «хвосты» и являются источником ошибочных вычислений десятичных действительных ЧПТ с помощью двоичной арифметики.

Машинный ноль *— числовое значение с таким отрицательным порядком, которое воспринимается машиной как ноль.* Число считается нулем, если все его биты, кроме знакового равны нулю.



В IEEE754 число «0» представляется значением с порядком, равным $E=E_{min}-1$ (для single это -127) и нулевой мантиссой.

Согласно стандарту IEEE754 ЧПТ считается равным бесконечности, если все двоичные разряды его порядка – единицы, а мантисса равна нулю. Знак бесконечности определяется знаковым битом числа. Получить бесконечность можно при переполнении и при делении ненулевого числа на ноль. При 0/0 предел не существует, поэтому результатом будет неопределенность.

Машинный эпсилон — числовое значение, меньше которого невозможно задавать относительную точность для любого алгоритма,

возвращающего вещественные числа. Абсолютное значение «машинного эпсилон» зависит от разрядности сетки применяемой ЭВМ, типа (разрядности) используемых при расчетах чисел, и от принятой в конкретном трансляторе структуры представления вещественных чисел (количества бит, отводимых на мантиссу и на порядок). Формально машинный эпсилон обычно определяют как минимальное из чисел ε, для которого $1+\varepsilon>1$ при машинных расчетах с числами данного типа. Альтернативное определение — максимальное ε, для которого справедливо равенство $1+\varepsilon=1$.

Практическая важность машинного эпсилон связана с тем, что два (отличных от нуля) числа являются одинаковыми с точки зрения машинной арифметики, если их относительная разность по модулю меньше (при определении первого типа) или не превосходит (при определении второго типа) машинного эпсилон.